

Rapport MLflow

Expériences Multi-modèles

Rayen Guermazi
ING4 DSA

12 mars 2026

Objectif

Ce document présente une synthèse des expériences exécutées via le backend (baseline, tuning et AutoML) et suivies avec **MLflow** dans le cadre du projet de classification *Heart Disease*.

Configuration

- Dataset : `data.csv` (cible : `target`)
- Seeds testées : [11, 42]
- Modèles : ['svm', 'random_forest', 'knn', 'logistic_regression', 'neural_network']
- Méthodes de tuning : ['grid', 'random', 'optuna'] (CV=3, n_iter / n_trials = 10)
- Nombre de runs : baseline = 10, tuning = 30, AutoML = 2, erreurs = 0

Résultats principaux

Moyennes F1 (baseline vs tuning)

Modèle	F1 baseline (moy.)	F1 tuning (moy.)	$\Delta F1$
svm	0.768	0.816	0.048
random_forest	0.800	0.802	0.002
knn	0.816	0.827	0.011
logistic_regression	0.818	0.809	-0.009
neural_network	0.837	0.835	-0.002

Top 3 des runs (triés par F1)

Famille	Modèle	Méthode	Seed	F1	Accuracy	ROC AUC
baseline	neural_network	none	42	0.845	0.820	0.867
tuned	neural_network	grid	42	0.845	0.820	0.867
tuned	neural_network	random	42	0.845	0.820	0.867

Hyperparamètres influents

Pour chaque couple (modèle, seed), nous retenons le meilleur run de tuning et les hyperparamètres associés.

Modèle	Seed	Méthode	F1	Meilleurs hyperparamètres (extrait)
knn	11	grid	0.836	"n_neighbors" : 11, "weights" : "distance"
knn	42	optuna	0.829	"n_neighbors" : 12, "weights" : "distance"
logistic_regression	11	grid	0.806	"C" : 0.1, "max_iter" : 300, "solver" : "lbfgs"
logistic_regression	42	grid	0.812	"C" : 0.1, "max_iter" : 300, "solver" : "lbfgs"
neural_network	11	grid	0.829	"early_stopping" : true, "hidden_layer_sizes" : [64, 32], "learning_rate_init" : 0.001, "max_iter" : 250
neural_network	42	grid	0.845	"early_stopping" : true, "hidden_layer_sizes" : [64, 32], "learning_rate_init" : 0.001, "max_iter" : 250
random_forest	11	grid	0.812	"max_depth" : 5, "min_samples_split" : 2, "n_estimators" : 100
random_forest	42	optuna	0.824	"n_estimators" : 208, "max_depth" : 3, "min_samples_split" : 2
svm	11	optuna	0.818	"C" : 0.272, "gamma" : 0.0206, "kernel" : "linear"
svm	42	optuna	0.829	"C" : 0.0600, "gamma" : 0.0746, "kernel" : "linear"

Conclusion

- Le tuning améliore principalement les performances de **SVM** et **KNN** sur ce dataset.
- Les gains restent limités pour **Random Forest** et ne sont pas systématiques pour **Logistic Regression** et **MLP**.
- Le meilleur résultat observé correspond à un **réseau de neurones (MLP)** avec la seed 42 et un score **F1** $\approx$ **0.845**.

Traçabilité MLflow

Toutes les expériences sont journalisées dans **MLflow** (paramètres, métriques, artefacts et versions des modèles).

Interface locale :

```
python -m mlflow ui -backend-store-uri sqlite:///backend/mlflow.db -host 127.0.0.1 -port 5000
```